Tugas GSLC Deep Learning
Giovan Prilsky Wongso
2802463812

Bagian A

1. Batch Normalization (disingkat jadi BN) menormalisasi aktivasi setiap layer per mini-batch. Karena mean dan variance dihitung dari subset data yang berubah tiap iterasi, muncul noise stokastik pada estimasi statistik. Noise ini membuat model tidak terlalu bergantung pada aktivasi spesifik suatu sampel, sehingga BN bertindak sebagai regularisasi ringan. Efeknya mirip Dropout: mengurangi overfitting dan memperhalus loss landscape. Oleh karena itu, BN sering menghilangkan kebutuhan Dropout, meskipun tidak selalu. Saat dalam masa prediksi, BN memakai running mean/variance sehingga output deterministik atau konsisten. Namun, ada suatu skenario saat batch size kecil, Batch Normalization bisa kurang stabil dan belum cukup mencegah overfitting, sehingga regularisasi tambahan seperti Dropout masih sangat diperlukan.
2. Adanya penambahan ke lapisan terhadap CNN itu justru membuat metrik akurasi menjadi tidak stabil atau berkurang. Secara pembahasan teori, layer tambahan minimal bisa menyamai model dangkal melalui identity mapping, tetapi fungsi identitas itu sulit dipelajari oleh tumpukan layer non-linear. Residual connection mengubah aliran menjadi $y = F(x) + x$. Saat backpropagation, gradient terhadap input menjadi $\partial L/\partial x = \partial L/\partial y\ (1 + \partial F/\partial x)$. Suku +1 tersebut menyediakan jalur langsung bagi gradient untuk mengalir ke layer awal tanpa harus melewati seluruh transformasi non-linear. Ini mengurangi pekerjaan vanishing gradient yang dibahas pada Sesi 02, karena gradient tidak terus-menerus mengecil saat melewati banyak layer. Model juga cukup mempelajari residual $F(x)$ menuju nol untuk mendekati identity mapping, sehingga optimasi menjadi lebih mudah. Ibaratnya kita bisa langsung melompati dari asli ke akhir tanpa menghilangkan informasi dan gradient di tengah jalan.
3. Yang namanya model-pretrained, berarti sudah dilatih dan pintar untuk menganalisis secara umum, Feature Extraction merupakan model yang sudah terlatih yang dimana bertindak “freezing” semua layer terlatih jadi cuman sedangkan Fine-Tuning merupakan sebuah metode yang dimana model tersebut akan dilatih ulang lagi.

Aspek	Feature Extraction	Fine Tuning
Jumlah parameter yang diperbarui (trainable parameters).	Sedikit, karena dia hanya fokus kepada bagian kepala.	Banyak, karena meliputi seluruh backbone.
Kebutuhan volume data latih	Sedikit	Lebih Banyak
Beban komputasi dan memori per epoch	Ringan dikomputasi	Berat untuk dikomputasi
Risiko rusaknya fitur representasi bawaan (destructive gradient updates)	Kecil	Besar

Kalau berbicara data yang sedikit dan tidak begitu ribet, pakai feature extraction saja, agar komputasi pun ringan. Kalau datanya banyak, baru pakai fine-tuning, tapi kalau bisa mulai dari layer bagian atas dahulu. Feature extraction kadang bisa underfit, jadi solusinya kita buka sebagian layer lagi untuk dimodelkan. Fine-tuning bisa menjadi brutal sehingga fitur lama bisa rusak, jadi sarankan pakai learning rate kecil untuk backbonenya.

4. Biasanya dalam kodingan machine learning, augmentation itu hanya dipakai dengan trained dataset, karena itu merupakan bagian masa pelatihan dari model, jadi dari train dataset tersebut kita bebas mau diapakan si dataset tersebut, contohnya aja dengan augmentasi agar kita bisa melihat semua hasil dari

dilakukan pelatihan tersebut, ini supaya si model bisa melihat semua dan mengenali objek tersebut dari sudut ke sudut dan pencahayaan bagaimana. Andaikata data uji atau test dataset itu dipakai augmentasi, itu berarti kan data ujiannya juga berserakkan di ubah-ubah, kalau sudah seperti itu, bagaimana mungkin suatu barang ketika dijadikan bahan uji dapat menghasilkan suatu output yang konsisten dan deterministik. Yang ada, hasil penilaian menjadi tidak adil dan tidak konsisten, bisa saja nanti outputnya kebetulan sama dan kita tidak tahu pasti apakah model yang kita gunakan itu sebenarnya pintar atau tidak, itu sebabnya augmentasi jangan pernah dipakai untuk dataset uji.

Contoh kasus dimana teknik transformasi citra yang tidak layak digunakan ketika merujuk pada klasifikasi ras hewan peliharaan adalah pemotongan bagian tubuh hewan tertentu, ini akibatnya bisa fatal, kenapa ? ada beberapa jenis ras hewan memiliki ciri karakteristik tubuh yang unik, yang justru lewat itu membedakan dirinya dengan ras lain, namun ketika dilakukan augmentasi yakni di cropping, maka ini akan memotong atau menghilangkan informasi penting dari si hewan tersebut dan labelnya menjadi tidak jelas.

5. Mengenai fenomena Catastrophic Forgetting, kita pakai cerita analogi saja biar jelas, ada suatu siswa yang sangat jago dalam matematika waktu dia SMP, tetapi ketika masuk jenjang SMA, materi pelajaran matematikanya sudah naik level dan sangat susah, sehingga dia perlu belajar-belajar terus agar dia bisa memahami konsepnya, ironisnya, oleh karena kerja keras yang terlalu over dalam belajar, hampir semua pelajaran matematika yang dipelajari waktu dia masih SMP itu dia lupa. Demikian juga dalam dunia deep learning, mungkin bobotnya sudah menyimpan informasi tentang suatu objek secara umum, namun kalau dilakukan fine-tuning seperti pada soal sebelumnya, dan itu terjadi sangat brutal, akhirnya bobot lama tersebut ketimpa oleh gradient data baru sehingga informasi lama dari objek tersebut menjadi hilang.

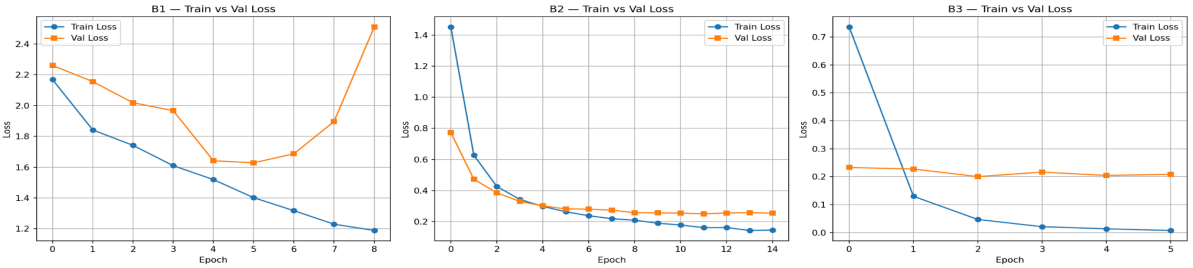
   Ada 2 mitigasi konkret:
   a. Differential Learning Rate
      Ini merupakan metode yang menggunakan learning rate yang kecil untuk bagian backbone dan learning rate yang besar untuk bagian kepala classifiernya. Tujuannya agar fitur umumnya tetap terjaga integritasnya sedangkan bagian kepala dari model bebas untuk beradaptasi dengan tugas baru.
   b. Gradual Unfreezing
      Bisa dibilang ini merupakan metode yang bekerja secara bertahap, mulai dari latihan head dulu dan bekukan backbonenya dulu. Nanti kalau sudah kelar, baru buka layer baru dan seterusnya sampai layer akhir, sehingga informasi dari objek itu tidak ada yang hilang sama sekali. Jadi, model beradaptasi secara *step by step* tanpa “kaget”.

Bagian C (Hasil analisis dari Kodingan)

1. Tabel Konsolidasi

Kondisi	Strategi	Trainable Params	Epochs	Durasi (detik)	Best Val Loss	Test Acc	Test Macro F1
B1	From Scratch	11.181.642	9	84.39	1.6287	38.26%	36.80%
B2	Feature Extraction	5.130	15	130.25	0.2498	94.30%	94.29%

B3	Fine-tune layer4	8.398.858	6	62.54	0.2004	94.30%	94.29%
B4	Fine-Tuning + Augmentation	8.398.858	9	115.54	0.1921	93.29%	93.30%
B5	EfficientNet-B0 + Augment	424.970	13	166.61	0.2509	93.62%	93.59%



Berdasarkan visualisasi grafik tersebut, ada perbandingan kurva training dan validation loss (B1, B2, B3)
B1: Train loss turun perlahan, tapi val loss naik tajam di epoch 8 → overfitting parah.
B2: Train dan val loss turun bersama, stabil, konvergen di epoch 15.
B3: Train loss turun sangat cepat (hampir 0), val loss stabil di ~0.20 → terjadi konvergen di epoch 6

2. a. Penyebab kenapa B1 sangat berbeda jauh hasilnya itu dikarenakan B1 harus belajar mulai dari nol dengan hanya sekitar 2000 gambar, Deep CNN memerlukan jutaan gambar untuk mempelajari fitur visual yang bagus sehingga berakhir overfitting yang parah.

   Untuk B2 dan B3, mereka menggunakan bobot ImageNet, dengan fitur low level yang sudah terlatih, jadi modelnya hanya perlu menyesuaikan kepala dari B2 atau layer 4 dari B3 untuk 10 kelas ras hewan tersebut.

   b. Dari tabel tersebut, hasil analisis:

   B2 sangat efisien bekerja yang membutuhkan sekitar 5000 param dan stabil. Ini cocok untuk data yang terbatas dan domain yang mirip ImageNet, B3 juga bekerja dengan baik, mencapai akurasi yang sama lebih cepat dan val loss lebih rendah, tapi ada kemungkinan terjadinya overfitting dengan adanya train loss ke angka 0.0007, yang berarti dia menghafal train datasetnya banyak banget.

   c. Dari perbedaan gap train-val untuk B3 dan B4, Augmentasi dari B4 memperkecil generalization gapnya (0.201 → 0.157), yang berarti model tidak lagi sempurna dalam menghafal training setnya. Tetapi val loss daripada B4 lebih rendah sehingga itu menandakan bahwa generalization lebih baik.

   Test Accuracy untuk B4 lebih rendah daripada B3 dikarenakan adanya generalisasi sehingga mengorbankan beberapa bagian dari training set tersebut.

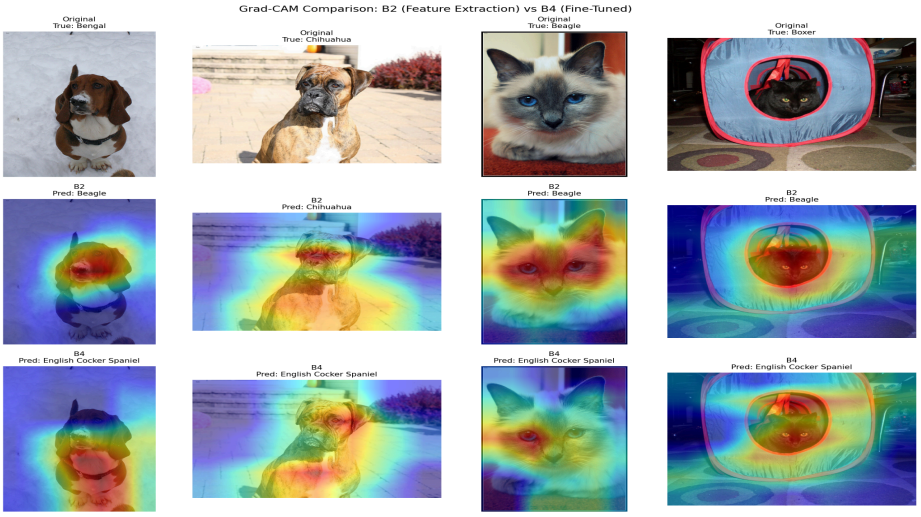
3. 

No	True Label	Prediksi	Isi Gambar Sebenarnya	Analisis
1	Boxer(Anjing)	English Cocker Spaniel	Kucing hitam dalam tenda	Seharusnya ini kucing, bukan anjing
2	British Shorthair	American Shorthair	Seekor anjing di atas kerikil	Seharusnya merujuk pada anjing, bukan kucing
3	English Cocker Spaniel (anjing)	Boxer	Kucing abu-abu di atas tilam ungu	Ini kucing, bukan, anjing
4	Birman (kucing)	British Shorthair	Anjing Pitbull di jalan	Label dataset salah, seharusnya anjing.
5	British Shorthair (kucing)	Abyssinian	Anjing kecil tidur secara telentang	Label dataset salah! Ini anjing.
6	American Shorthair (kucing)	Birman	Anjing besar duduk di taman	Label dataset salah, ini anjing.
7	British Shorthair	Bengal	Anjing tidur di selimut	Label dataset juga salah, ini anjing.
8	Chihuahua (anjing)	American Shorthair	Anjing putih kecil berlari	Label sudah benar, hanya saja model salah prediksi, dikiranya kucing.

Berdasarkan analisis terhadap delapan sampel misklasifikasi dari model B4, ditemukan bahwa model memiliki confidence score 0,44–0,77, menandakan representasi fitur yang cukup kuat. Namun, temuan utama adalah adanya label noise signifikan pada dataset Oxford-IIIT Pet, tujuh dari delapan kasus merupakan gambar yang labelnya tidak sesuai dengan isi visual (kucing dilabeli anjing, atau sebaliknya). Akibatnya, model "belajar dari label yang salah", sehingga prediksinya secara visual benar namun dianggap salah karena dibandingkan dengan ground truth yang keliru. Hanya satu kasus yang murni kesalahan model (Chihuahua dengan motion blur). Dengan demikian, akurasi 93,29% pada B4 justru lebih impresif karena model berlatih dan dievaluasi pada dataset ber-noise tinggi. Temuan ini menegaskan pentingnya audit kualitas label sebelum training. Implikasi praktisnya bagi tim rekayasa adalah perlunya tahap validasi label (misalnya melalui cross-check anotasi atau label smoothing) sebelum model dilatih, karena kualitas label menentukan batas atas performa model.

4. Berdasarkan hasil uji koding eksperimen dari B1–B5, rekomendasi praktis untuk tim rekayasa dalam skenario small-data regime adalah mulai dari feature extraction (B2) karena paling efisien (hanya memerlukan 5.130 parameter, akurasi 94,30%), naikkan ke progressive fine-tuning (B3) jika performa kurang (konvergen 6 epoch, val loss lebih rendah), tambahkan augmentasi (B4) hanya ketika terjadinya overfitting terdeteksi (menekan generalization gap dari 0,201 ke 0,157), dan pertimbangkan arsitektur ringan (B5, Efficient Net-B0) untuk deployment di perangkat edge (425.000 parameter, akurasi 93,62%). Hindari training from scratch (B1) pada data terbatas karena hanya mencapai 38,26%.

Adapun batasan studi ini meliputi yakni penggunaan single seed (42) tanpa cross-validation, pembatasan pada 10 kelas dari 37 kelas Oxford-IIIT Pet, ditemukannya label noise signifikan pada dataset (7 dari 8 kasus misklasifikasi), keterbatasan anggaran komputasi (Colab T4, maksimum 15 epoch), serta tidak diujinya teknik mitigasi label noise seperti label smoothing atau mixup. Hasil studi ini valid untuk domain mirip ImageNet, namun perlu divalidasi ulang untuk domain yang sangat berbeda seperti citra medis atau industri.

5. 

Visualisasi Grad-CAM pada layer4 ResNet-18 membandingkan B2 (feature extraction) dan B4 (fine-tune + augmentasi). Pada B2, model konsisten memfokuskan perhatian pada wajah dan kepala hewan—area diskriminatif untuk membedakan ras. Sebaliknya, B4 mengalami mode collapse: model memprediksi "English Cocker Spaniel" untuk semua gambar uji, dengan Grad-CAM menunjukkan fokus pada seluruh tubuh dan latar belakang (tenda, paving, selimut) alih-alih fitur wajah. Temuan ini konsisten dengan C3: label noise yang parah pada dataset menyebabkan fine-tuning agresif meng-overfit pada korelasi palsu, sehingga justru merusak representasi yang sudah baik. Sebaliknya, B2 yang hanya melatih classifier head terbukti lebih robust terhadap label noise, meskipun akurasinya setara (94,30%). Kesimpulannya, fine-tuning hanya layak dilakukan setelah dataset diaudit dan dipastikan bersih, sejalan dengan best practice Slide 29.

Lampiran Penggunaan AI

Saya menggunakan Gemini dan Deepseek untuk debugging kode PyTorch, klarifikasi konsep, dan penyempurnaan tata bahasa dan mencari informasi mengenai topik ini. Semua keluaran AI diverifikasi melalui eksperimen langsung di Google Colab, pengecekan dokumentasi resmi, dan analisis mandiri berbasis log mentah. Seluruh interpretasi dan kesimpulan merupakan pemahaman saya sendiri.

Giovan Prilsky Wongso — 2802463812 — Senin, 12 Oktober 2026